

Exploration sur les données des catastrophes climatiques

Projet Libre 2 - Python pour Data Science

ASSANOUSI
IKHLAS

SIMPORE
WINDPOUIRE FLORE

EL YAMANI
OUMAIMA

Université Hassan II - FST Mohammedia

Année Universitaire 2025-2026

Plan de la Présentation

- 1 Introduction
- 2 Bibliothèques utilisées
- 3 Exploration des données
- 4 Analyse et Visualisation
- 5 Traitement avancé

Contexte

Contexte

La question climatique demeure un défi majeur à l'échelle mondiale. Dans ce contexte, notre étude porte sur l'analyse d'un jeu de données climatiques recensant les **catastrophes naturelles** survenues dans le monde entre le **1^{er} janvier 2020** et le **15 septembre 2025**. Ce dataset décrit la **sévérité** des événements ainsi que leurs **conséquences humaines, économiques et matérielles**.

Objectifs du Projet

- ✓ **Explorer** les données climatiques mondiales
- ✓ **Analyser et visualier** les résultats
- ✓ **Prédire** la sévérité des événements climatiques

Question Principale

Comment réaliser ces objectifs en utilisant les bibliothèques Python ?

Visualisation interactive

Pour une approche plus interactive et intuitive, nous avons utilisé Streamlit afin d'afficher, explorer et visualiser nos résultats de manière dynamique.

Les bibliothèques Python utilisées

Exploration et préparation

NumPy : calcul scientifique et manipulation de tableaux.

Pandas : importation, nettoyage et analyse statistique des données.

Modélisation et prédiction

Scikit-learn : création, entraînement et évaluation de modèles prédictifs à partir des données préparées.

Visualisation et analyse

Plotly : graphiques interactifs pour analyses dynamiques.

Déploiement et interaction

Streamlit : exécution du script Python sous forme d'application web interactive pour présenter les résultats.

Exploration des données

Objectif


Comprendre les caractéristiques des données

- **Taille des données** : 3000 instances, 20 variables
- **Types de données** : Variables catégorielles (event-type, country) et variables numériques (severity, economic-impact-million-usd, infrastructure-damage-score ...)
- **Qualité des données** : Absence de valeurs manquantes et de doublons
- **Résumé statistique** : Voir l'application web pour plus de détails


Distributions des Variables

Éléments Analysés

- Histogrammes des variables numériques
- Détection des valeurs aberrantes
- Distribution des variables catégorielles



Corrélations entre Variables




Interprétation

- ✓ **Forte corrélation positive** entre sévérité et :
 - Score de Dégâts aux Infrastructures
 - Nombre Total de Victimes
- ✓ **Corrélation importante** entre durée (jours) et Impact par Habitant

Implication

Les événements graves causent davantage de dégâts et de victimes.

Temps de Réponse par Pays et Année



- Variation significative du temps de réponse selon les pays et les années.

Traitement avancé


Objectif : prédire les **la sévérité de l'événement** à partir des variables du dataset.

Méthodologie :

- Régression linéaire avec Scikit-learn ;
- Données séparées en *train/test* ;
- Évaluation par R^2 et MSE ;
- Estimation des coefficients β expliquant y .

$$y = \beta_0 + \sum_{i=1}^n \beta_i x_i + \varepsilon$$

Résultats du modèle



Résultats

- Relation **positive** entre la sévérité et les pertes économiques ;
- $R^2 = 0.61 \rightarrow$ le modèle explique 61 % de la variabilité ;
- $MSE = 1.67 \Rightarrow RMSE = 1.29$;
- Les prédictions s'écartent en moyenne de 1.29 unité (sévérité : 1–9).

Discussion et conclusion

- Les pertes augmentent avec la gravité et la durée des événements ;
- Les inondations et incendies causent les impacts les plus forts ;
- Le modèle capture les tendances, mais reste perfectible ;
- De nouvelles variables (densité urbaine, politiques locales) pourraient améliorer la précision.

Conclusion : Cette étude illustre le cycle complet d'un projet de **science des données**, reliant les *facteurs climatiques* aux *conséquences économiques* des catastrophes naturelles.