

UNIVERSITÉ HASSAN II DE CASABLANCA
Faculté des Sciences et Techniques de
Mohammedia



Département Mathématique

Filière Ingénierie

Data Science et Informatique (IDSI)

Exploration et Analyse d'un Dataset Climatique

Réalisé par :

ASSANOUSI IKHLAS SIMPORE WINDPOUIRE FLORE
EL YAMANI OUMAIMA

Encadré par :

PR. ANOUAR BEN-LOGHFYRY

Année Universitaire 2024-2025

Table des matières

1	Introduction	2
2	Exploration des données	2
3	Analyse et visualisation	3
3.1	Distributions des Variables	3
3.2	Corrélations entre variables	3
3.3	Temps de Réponse par Pays et Année	3
4	Traitement avancé	5
4.1	Méthodologie	5
4.2	Résultats du modèle	6
5	Discussion	6
6	Conclusion	6

1 Introduction

Le changement climatique constitue aujourd'hui un enjeu mondial majeur. Afin de mieux comprendre les dynamiques et conséquences liées aux phénomènes naturels extrêmes, nous avons choisi d'analyser un **dataset climatique** recensant les catastrophes naturelles survenues entre le **1^{er} janvier 2020** et le **15 septembre 2025**. Ce jeu de données présente pour chaque événement des informations sur la **localisation**, la **date**, la **gravité**, les **impacts humains** et **économiques**.

Les objectifs du projet sont :

- Explorer et comprendre la structure du dataset ;
- Visualiser les principales tendances et corrélations ;
- Prédire la sévérité des événements naturelles.

2 Exploration des données

Cette étape permet de comprendre les caractéristiques des données et de détecter les problèmes potentiels afin d'uniformiser celles-ci. Pour cette étape, nous avons principalement utilisé les bibliothèques **NumPy** et **Pandas**. **NumPy** facilite la manipulation efficace des tableaux numériques et les calculs mathématiques, tandis que **Pandas** offre des structures de données puissantes telles que les **DataFrames**, permettant de charger, explorer et transformer les données de manière intuitive et rapide.

Pour rendre les visualisations interactives et accessibles directement dans un site web plutôt que dans la console, nous avons utilisé Streamlit.

Description des données : Les données utilisées pour ce projet comportent 3000 instances et 20 variables (catégorielles et numériques).

Qualité des données : aucune présence de valeurs manquantes ni de doublons.

	year	month	severity	duration_days	affected_population	deaths	injuries	economic_impact_million_usd	infrastructure_damage_score
count	3000.000000	3000.000000	3000.000000	3000.000000	3.000000e+03	3000.000000	3000.000000	3000.000000	3000.000000
mean	2022.401667	6.260333	3.786333	8.783000	8.685505e+05	4.615000	39.228333	1.944367	15.160733
std	1.653857	3.367146	2.005165	14.714508	3.009690e+06	11.021491	78.812194	15.734990	11.501826
min	2020.000000	1.000000	1.000000	0.000000	6.220000e+02	0.000000	0.000000	0.000000	0.200000
25%	2021.000000	3.000000	2.000000	1.000000	5.451775e+04	1.000000	10.000000	0.010000	6.000000
50%	2022.000000	6.000000	4.000000	2.000000	1.784770e+05	2.000000	18.000000	0.090000	12.400000
75%	2024.000000	9.000000	5.000000	9.000000	6.082012e+05	3.000000	27.000000	0.530000	21.425000
max	2025.000000	12.000000	9.000000	115.000000	5.624832e+07	117.000000	734.000000	718.210000	63.000000

FIGURE 1 – Statistiques descriptives des variables numériques (partie 1).

response_time_hours	international_aid_million_usd	latitude	total_casualties	impact_per_capita	aid_percentage
3000.000000	3000.000000	3000.000000	3000.000000	3000.000000	3000.000000
11.107667	0.057020	4.166829	43.843333	3.613917	0.009267
8.255753	3.005868	492.219402	85.943626	10.779860	0.427530
0.000000	0.000000	-897.563000	0.000000	0.000000	0.000000
5.000000	0.000000	-383.632000	11.000000	0.080000	0.000000
9.000000	0.000000	-5.409500	20.000000	0.480000	0.000000
15.000000	0.000000	419.996000	29.000000	2.132500	0.000000
60.000000	164.510000	899.769000	738.000000	181.620000	22.900000

FIGURE 2 – Statistiques descriptives des variables numériques (partie 2).

Pour les variables catégorielles, les fréquences des catégories sont présentées dans le tableau suivant :

	country	event_type
count	3000	3000
unique	51	12
top	Japan	Earthquake
freq	86	287

FIGURE 3 – Statistiques descriptives des variables catégorielles.

L’exploration de données a permis de mettre en évidence les caractéristiques clés des données. Les résultats de cette analyse seront pris en compte dans le développement du modèle de Machine Learning.

3 Analyse et visualisation

Nous avons réalisé quelques visualisations pour mieux comprendre les tendances du dataset. Pour cette partie, nous avons principalement utilisé les bibliothèques **Pandas**, **Plotly**. **Pandas** a été utilisée pour manipuler et regrouper les données, tandis que **Plotly** a permis de produire des graphiques clairs et informatifs.

3.1 Distributions des Variables

L’analyse des distributions nous permet de comprendre la forme et la dispersion de chaque variable dans notre dataset. La Figure 4 montre les distributions des variables numériques et la détection des valeurs abberantes.

3.2 Corrélations entre variables

Une matrice de corrélation a été calculée, 5, pour identifier les liens entre les variables, notamment entre la sévérité, le nombre de victimes et les pertes économiques.

3.3 Temps de Réponse par Pays et Année

La Figure 6 représente le temps de réponse moyen pour chaque pays, année par année. Les cellules plus rouges indiquent des délais de réponse plus longs, tandis que les cellules jaunes/blanches indiquent une réactivité plus rapide.




FIGURE 4 – Distributions des variables numériques et détection d'outliers

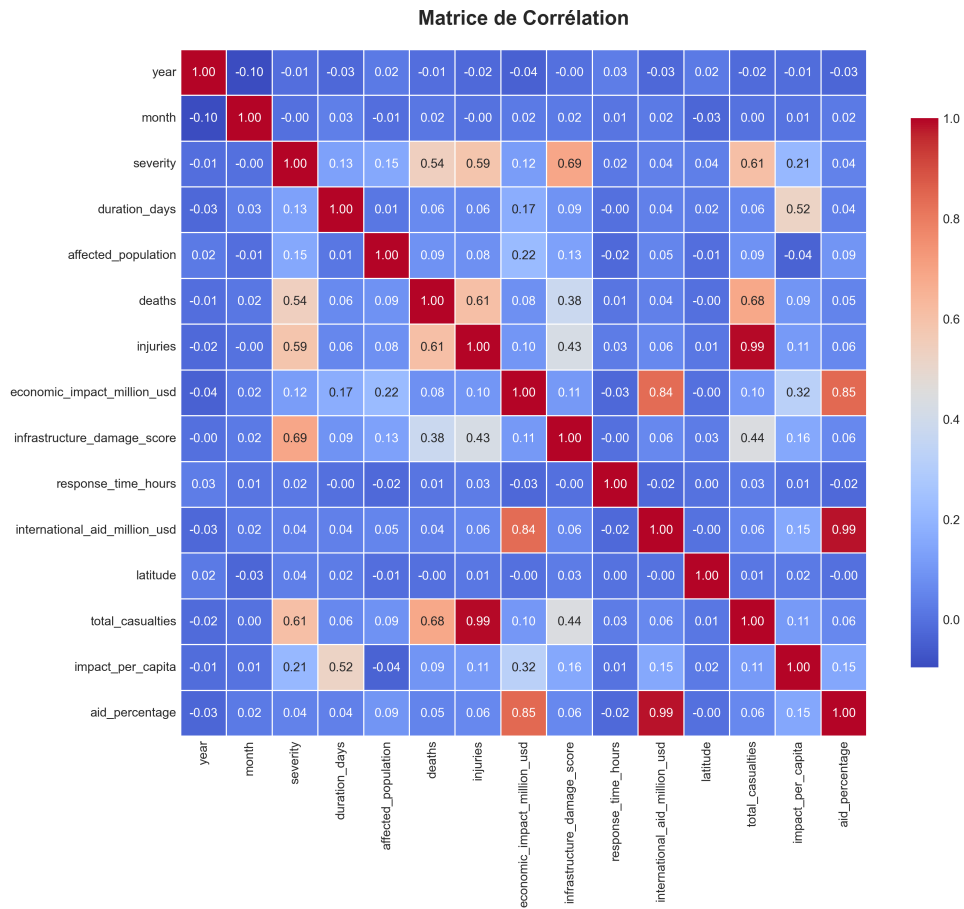


FIGURE 5 – Matrice de corrélation entre les principales variables du dataset.

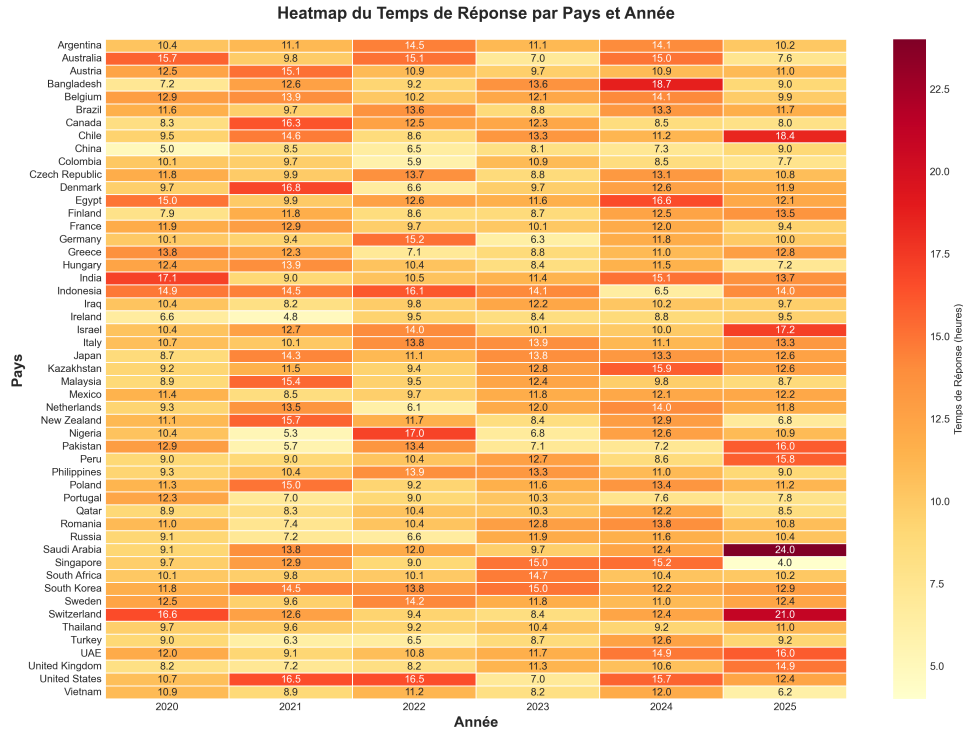


FIGURE 6 – Heatmap du temps de réponse moyen par pays et année (cellules rouges = délais longs)

4 Traitement avancé

L'objectif est de prédire les **la sévérité** à partir des autres variables du dataset.

4.1 Méthodologie

Nous avons utilisé la bibliothèque **Scikit-learn** pour implémenter un modèle de régression linéaire. Les principales étapes sont les suivantes :

- Séparation des données en deux ensembles : *entraînement* et *test* ;
- Entraînement du modèle de régression linéaire ;
- Évaluation du modèle à l'aide des métriques : coefficient de détermination (R^2) et erreur quadratique moyenne (MSE) ;
- Estimation des coefficients β associés aux variables explicatives $\mathbf{X}$ qui expliquent la variable cible y .

Sur le plan mathématique, le modèle de régression linéaire peut s'écrire sous la forme :

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n + \varepsilon$$

ou, en notation vectorielle :

$$\mathbf{y} = \mathbf{X}\beta + \varepsilon$$

où :

- $\mathbf{y}$ est le vecteur des valeurs observées de la variable cible (sévérité des événements climatiques) ;
- $\mathbf{X}$ est la matrice des variables explicatives (les victimes, le score des dégâts) ;
- β est le vecteur des coefficients estimés ; ε représente le terme d'erreur .

4.2 Résultats du modèle

Les résultats montrent une relation positive entre la sévérité des événements et les pertes économiques, représentées par le score des dégâts et le nombre de victimes.

Le modèle de régression linéaire obtient un coefficient de détermination de $R^2 = 0.61$, indiquant qu'il explique environ 61 % de la variabilité de la variable cible. L'erreur quadratique moyenne est de $\text{MSE} = 1.67$, ce qui correspond à une racine de l'erreur quadratique moyenne $\text{RMSE} = 1.29$. Ainsi, les prédictions du modèle présentent en moyenne un écart d'environ 1.29 unité (dans notre cas la sévérité varie entre 1 et 9) par rapport aux valeurs observées.




FIGURE 7 – Performance du modèle prédictif.

5 Discussion

Cette analyse met en évidence plusieurs enseignements :

- Les pertes économiques augmentent avec la gravité et la durée des catastrophes ;
- Certains types d'événements, comme les inondations et les incendies, génèrent les impacts les plus élevés ;
- Le modèle de régression capture partiellement ces tendances, mais des variables contextuelles (comme la densité urbaine ou la politique de réponse) pourraient améliorer la prédiction.

6 Conclusion

Ce projet nous a permis de parcourir l'ensemble du cycle d'un projet de science des données : de l'exploration du dataset à la modélisation prédictive. L'étude met en lumière la relation entre les paramètres climatiques et les conséquences économiques des catastrophes naturelles.